

Lab 2/3 实验手册

2026.4.10

目录

Lab 2/3 实验手册.....	
. 1注意.....	
. 11 下载 python 依赖包和大模型.....	
1.1 下载 anaconda 工具.....	2
1.2 下载本次实验所需的 python 依赖包	2
1.3 从 huggingface 上面下载大模型.....	5
2 获取模型的 APIKEY.....	6
2.1“百炼”平台(免费调用 DeepSeek).....	6
2.2“MiniMax”模型.....	9
2.3“DeepSeek”模型(收费).....	12
2.4“文心一言”模型(收费).....	13
3 调用大模型 API.....	20
3.1 创建测试脚本文件.....	20
3.2 通过 openai 调用 api	25
4 本地部署大模型	27
4.1 填写大模型路径.....	27
4.2 重新启动程序	27
4.3 测试模型推理功能.....	27
5 通过“gradio”生成页面 UI	27
5.1 启动 gradio 后台	27
5.2 测试前端 UI 界面.....	29
6 通过“html”生成页面 UI.....	30
6.1 创建 html 文件	30
6.2 建立 python 后台服务器.....	31

注意

- ① 该实验手册的实验主要是在 Anaconda+Vscode 的配置下完成的，也建议大家安装 anaconda 环境来管理多个 python 环境；
- ② 只要能成功运行，就不需要完全按照实验手册配置；手册仅供参考，运行不成功的同学可以参考配置；
- ③ 实验手册里的安装问题是助教在运行时遇到的，经过搜索查找以后分析原因并解决，不包含全部的问题；遇到问题需要先查看系统输出的 error，里面信息量充足，可以复制 error 去搜索引擎查找答案，除非遇到过否则都是执行这个步骤，所以大家要善用搜索工

具并且多尝试，实在难以解决的情况再带着系统输出的 error 截图询问助教~

- ④ “通义千问”和“MiniMax”的 APIKEY 可以免费申请使用，“deepSeek”和“文心一言”的 APIKEY 只有收费模式(<https://api-docs.deepseek.com/>、<https://cloud.baidu.com/doc/WENXINWO/RKSHOP/s/2m3fihw8s>) 但是使用“通义千问”的 APIKEY 也可以免费调用 DeepSeek 的模型，只需要将配置中的“model”设置为“deepseek-v3”、“deepseek-r1”等。

1 下载 python 依赖包和大模型

1.1 下载 anaconda 工具

(1) 下载:

Windows 系统的 anaconda 安装包:

https://repo.anaconda.com/archive/Anaconda3-2024.10-1-Windows-x86_64.exe

(2) 安装:

anaconda 安装教程: https://blog.csdn.net/qq_45281589/article/details/134597810

(3) 使用:

anaconda+vscode 可以参照:


https://www.bilibili.com/video/BV1bQ4y1n7sn/?spm_id_from=333.788.top_right_bar_window_custom_collection.content.click&vd_source=ab9487b4c2a08af5aa95fc4a529cabca

1.2 下载本次实验所需的 python 依赖包

(1) 创建虚拟环境

在命令行中执行这个命令:

```
conda create -n lab2 python=3.10
```



```
Microsoft Windows [版本 10.0.22631.5189]
(c) Microsoft Corporation. 保留所有权利。

C:\Users\28142\Desktop\lab2>conda create -n lab2 python=3.10
Collecting package metadata (current_repodata.json): done
Solving environment: done

## Package Plan ##

  environment location: C:\Users\28142\.conda\envs\lab2

added / updated specs:
- python=3.10

The following packages will be downloaded:

package                                     build                                size
-----
bz2-1.0.8                                  h2b8ff1b_6                          98 KB
ca-certificates-2025.2.25                  haa95532_0                          138 KB
libffi-3.4.4                                h77b12b1_1                          122 KB
openssl-3.0.16                             h3f729d1_0                           7.8 MB
pip-25.0                                    py310haa95532_0                      2.5 MB
python-3.10.16                              h4687a30_1                          16.3 MB
setuptools-75.0.0                          py310haa95532_0                      1.7 MB
sqlite-3.45.3                              h2b8ff1b_0                           973 KB
tk-8.6.14                                  h0416ee5_0                           3.5 MB
tzdata-2025a                              h04d1e81_0                          117 KB
vc-14.42                                  haa95532_5                           11 KB
vs2015_runtime-14.42.34433                 hbfb682d_5                          1.2 MB
wheel-0.45.1                               py310haa95532_0                      115 KB
```

输入 y

```
C:\Windows\System32\cmd.e  X  +  v

python-3.10.16          | h4607a30_1      16.3 MB
setuptools-75.8.0      | py310haa95532_0 1.7 MB
sqlite-3.45.3          | h2bbff1b_0      973 KB
tk-8.6.14              | h0416ee5_0      3.5 MB
tzdata-2025a           | h04d1e81_0      117 KB
vc-14.42               | haa95532_5       11 KB
vs2015_runtime-14.42.34433 | hbfb602d_5      1.2 MB
wheel-0.45.1           | py310haa95532_0 145 KB
xz-5.6.4               | h4754444_1      280 KB
zlib-1.2.13            | h8cc25b3_1      131 KB
-----
Total:                  34.9 MB

The following NEW packages will be INSTALLED:

bzip2                pkgs/main/win-64::bzip2-1.0.8-h2bbff1b_6
ca-certificates      pkgs/main/win-64::ca-certificates-2025.2.25-haa95532_0
libffi               pkgs/main/win-64::libffi-3.4.4-hd77b12b_1
openssl              pkgs/main/win-64::openssl-3.0.16-h3f729d1_0
pip                  pkgs/main/win-64::pip-25.0-py310haa95532_0
python               pkgs/main/win-64::python-3.10.16-h4607a30_1
setuptools            pkgs/main/win-64::setuptools-75.8.0-py310haa95532_0
sqlite                pkgs/main/win-64::sqlite-3.45.3-h2bbff1b_0
tk                    pkgs/main/win-64::tk-8.6.14-h0416ee5_0
tzdata                pkgs/main/noarch::tzdata-2025a-h04d1e81_0
vc                    pkgs/main/win-64::vc-14.42-haa95532_5
vs2015_runtime        pkgs/main/win-64::vs2015_runtime-14.42.34433-hbfb602d_5
wheel                 pkgs/main/win-64::wheel-0.45.1-py310haa95532_0
xz                    pkgs/main/win-64::xz-5.6.4-h4754444_1
zlib                  pkgs/main/win-64::zlib-1.2.13-h8cc25b3_1

Proceed ([y]/n)? y
```

完成

```
管理员: 命令提示符 - conda remove -n lab2 --all

vc                pkgs/main/win-64::vc-14.42-haa95532_5 None
vs2015_runtime    pkgs/main/win-64::vs2015_runtime-14.42.34433-hbfb602d_5 None
wheel             pkgs/main/win-64::wheel-0.45.1-py310haa95532_0 None
xz                pkgs/main/win-64::xz-5.6.4-h4754444_1 None
zlib              pkgs/main/win-64::zlib-1.2.13-h8cc25b3_1 None

Proceed ([y]/n)? y

Downloading and Extracting Packages
vs2015_runtime-14.42 | 1.2 MB | ##### | 100%
vc-14.42              | 11 KB | ##### | 100%
Preparing transaction: done
Verifying transaction: done
Executing transaction: done

#
# To activate this environment, use
#
#     $ conda activate lab2
#
# To deactivate an active environment, use
#
#     $ conda deactivate
#

Retrieving notices: ...working... done
C:\Users\Administrator\Desktop\lab2>
```

(2) 进入虚拟环境

在命令行中执行这个命令：

```
activate lab2
```

```
管理员: 命令提示符 - conda remove -n lab2 --all - activate lab2

wheel                pkgs/main/win-64::wheel-0.45.1-py310h8a95532_0 None
xz                   pkgs/main/win-64::xz-5.6.4-h4754444_1 None
zlib                 pkgs/main/win-64::zlib-1.2.13-h8cc25b3_1 None

Proceed ([y]/n)? y

Downloading and Extracting Packages
vs2015_runtime-14.42 | 1.2 MB | ##### | 100%
vc-14.42             | 11 KB | ##### | 100%
Preparing transaction: done
Verifying transaction: done
Executing transaction: done
#
# To activate this environment, use
#
#     $ conda activate lab2
#
# To deactivate an active environment, use
#
#     $ conda deactivate
#
Retrieving notices: ...working... done

C:\Users\Administrator\Desktop\lab2>activate lab2

C:\Users\Administrator\Desktop\lab2>conda.bat activate lab2

(lab2) C:\Users\Administrator\Desktop\lab2>_
```

(3) 安装依赖包

在命令行中执行这个命令：

```
pip install openai transformers torch accelerate gradio flask flask-socketio

管理员: 命令提示符 - conda remove -n lab2 --all - activate lab2

(lab2) C:\Users\Administrator\Desktop\lab2>pip install openai
Collecting openai
  Downloading openai-1.75.0-py3-none-any.whl.metadata (25 kB)
Collecting anyio<5,>=3.5.0 (from openai)
  Using cached anyio-4.9.0-py3-none-any.whl.metadata (4.7 kB)
Collecting distro<2,>=1.7.0 (from openai)
  Using cached distro-1.9.0-py3-none-any.whl.metadata (6.8 kB)
Collecting httpx<1,>=0.23.0 (from openai)
  Using cached httpx-0.28.1-py3-none-any.whl.metadata (7.1 kB)
Collecting jiter<1,>=0.4.0 (from openai)
  Using cached jiter-0.9.0-cp310-cp310-win_amd64.whl.metadata (5.3 kB)
Collecting pydantic<3,>=1.9.0 (from openai)
  Using cached pydantic-2.11.3-py3-none-any.whl.metadata (65 kB)
Collecting sniffio (from openai)
  Using cached sniffio-1.3.1-py3-none-any.whl.metadata (3.9 kB)
Collecting tqdm>4 (from openai)
  Using cached tqdm-4.67.1-py3-none-any.whl.metadata (57 kB)
Collecting typing_extensions<5,>=4.11 (from openai)
  Downloading typing_extensions-4.13.2-py3-none-any.whl.metadata (3.0 kB)
Collecting exceptiongroup>=1.0.2 (from anyio<5,>=3.5.0->openai)
  Using cached exceptiongroup-1.2.2-py3-none-any.whl.metadata (6.6 kB)
Collecting idna>=2.8 (from anyio<5,>=3.5.0->openai)
  Using cached idna-3.10-py3-none-any.whl.metadata (10 kB)
Collecting certifi (from httpx<1,>=0.23.0->openai)
  Using cached certifi-2025.1.31-py3-none-any.whl.metadata (2.5 kB)
Collecting httpcore==1.* (from httpx<1,>=0.23.0->openai)
  Downloading httpcore-1.0.8-py3-none-any.whl.metadata (21 kB)
Collecting h11<0.15,>=0.13 (from httpcore==1.*->httpx<1,>=0.23.0->openai)
  Using cached h11-0.14.0-py3-none-any.whl.metadata (8.2 kB)
Collecting annotated-types>=0.6.0 (from pydantic<3,>=1.9.0->openai)
```

```
选择 管理员: 命令提示符 - conda remove -n lab2 --all - activate lab2
Using cached colorama-0.4.6-py2.py3-none-any.whl.metadata (17 kB)
Downloading openai-1.75.0-py3-none-any.whl (646 kB)
647.0/647.0 kB 328.4 kB/s eta 0:00:00
Using cached anyio-4.9.0-py3-none-any.whl (100 kB)
Using cached distro-1.9.0-py3-none-any.whl (20 kB)
Using cached httpx-0.28.1-py3-none-any.whl (73 kB)
Downloading httpcore-1.0.8-py3-none-any.whl (78 kB)
Using cached jiter-0.9.0-cp310-cp310-win_amd64.whl (208 kB)
Using cached pydantic-2.11.3-py3-none-any.whl (443 kB)
Using cached pydantic_core-2.33.1-cp310-cp310-win_amd64.whl (2.0 MB)
Using cached sniffio-1.3.1-py3-none-any.whl (10 kB)
Using cached tqdm-4.67.1-py3-none-any.whl (78 kB)
Downloading typing_extensions-4.13.2-py3-none-any.whl (45 kB)
Using cached annotated_types-0.7.0-py3-none-any.whl (13 kB)
Using cached exceptiongroup-1.2.2-py3-none-any.whl (16 kB)
Using cached idna-3.10-py3-none-any.whl (70 kB)
Using cached typing_inspection-0.4.0-py3-none-any.whl (14 kB)
Using cached certifi-2025.1.31-py3-none-any.whl (166 kB)
Using cached colorama-0.4.6-py2.py3-none-any.whl (25 kB)
Using cached hll-0.14.0-py3-none-any.whl (58 kB)
Installing collected packages: typing-extensions, sniffio, jiter, idna, hll, exceptiongroup, distro, colorama, certifi,
annotated-types, typing-inspection, tqdm, pydantic-core, httpcore, anyio, pydantic, httpx, openai
Successfully installed annotated-types-0.7.0 anyio-4.9.0 certifi-2025.1.31 colorama-0.4.6 distro-1.9.0 exceptiongroup-1.
2.2 hll-0.14.0 httpcore-1.0.8 httpx-0.28.1 idna-3.10 jiter-0.9.0 openai-1.75.0 pydantic-2.11.3 pydantic-core-2.33.1 snif
fio-1.3.1 tqdm-4.67.1 typing-extensions-4.13.2 typing-inspection-0.4.0
(lab2) C:\Users\Administrator\Desktop\lab2>
```

1.3 从 huggingface 上面下载大模型

(1) 创建一个 download.py 文件

文件 download.py 的内容为：

```
from huggingface_hub import snapshot_download

#DeepSeek-R1-Distill-Qwen-1.5B/7B 或 DeepSeek-V2-Lite
model_id = "deepseek-ai/DeepSeek-Coder-V2-Lite-Instruct"
# model_id = "deepseek-ai/DeepSeek-Coder-V2-Lite-Base"
# model_id = "deepseek-ai/DeepSeek-R1-Distill-Qwen-1.5B"
# model_id = "deepseek-ai/DeepSeek-R1-Distill-Qwen-7B"

# 下载模型到指定目录
snapshot_download(
    repo_id=model_id,
    local_dir="./DeepSeek-Model", # 本地保存路径
    resume_download=True,        # 启用断点续传
    local_dir_use_symlinks=False # 不使用符号链接，复制实际文件
)
```

(2) 执行大模型的项目下载脚本

先打开 VPN，然后执行脚本：

```
python download.py
```

2 获取模型的 APIKEY

2.1“百炼”平台(免费调用 DeepSeek)

2.1.1 官方教程

<https://help.aliyun.com/zh/model-studio/get-api-key?spm=a2c4g.11186623.0.0.74b04823Yw4aeD>




2.1.2 注册阿里云账号


(1) 点击右上角的“注册”按钮



(2) 使用手机的支付宝扫描左侧的二维码



(3) 通过手机上的支付宝软件扫描二维码后，点击确认登录




(4) 确认后电脑网页会自动跳转回到主页，并且右上角此时会显示用户名。




2.1.3 获取一个 API-KEY


(1) 下拉一下前面这个网页的滚动条后可以看到一个超链接“API KEY”，点击它。



(2) 在自动弹出的新窗口中点击“创建 API KEY”这个按钮。



(3) 点击“确认”按钮。



(4) 在弹出的“保存你的 API Key”窗口中点击“复制”按钮，保存获取的 API Key。




(5) 左侧菜单点击“模型用量”，可以查看可用的模型。



2.2“MiniMax”模型


2.2.1 官方教程

<https://platform.minimaxi.com/docs/api-reference/api-overview>




2.2.2.注册账号并实名认证


(1) 点击右上角的“登录”按钮。




(2) 输入手机号码和验证码，点击“登录/注册”按钮。



(3) 填入姓名和密码后，点击“立即注册”按钮，完成注册。




(4) 点击“开始实名认证”按钮，按照提示完成实名认证。



2.2.3 获取一个 API-KEY

(1) 完成实名认证后，点击“获取你的 key”按钮。



(2) 系统会自动创建一个“体验中心”key，点击“复制”，得到 API Key 并保存。



2.3“DeepSeek”模型(收费)


2.3.1 官方教程

<https://api-docs.deepseek.com/zh-cn/>

<https://api-docs.deepseek.com/>



2.3.2 得到 API key



注：获取的 API-KEY 在没有缴费前无法获取 DEEP SEEK 的响应(返回提示“You exceeded your current quota, please check your plan and billing details”)。

2.3.3 缴费



2.4“文心一言”模型(收费)

2.4.1 官方教程

<https://cloud.baidu.com/doc/WENXINWORKSHOP/s/2m3fihw8s>




2.4.2.注册账号并实名认证

(1) 点击右上角的“免费注册”按钮




(2) 填写完所有信息后点击“注册”按钮



(3) 在实名认证弹窗中点击“个人刷脸认证”




(4) 填写完信息后点击“提交认证”按钮




(5) 通过手机的微信 APP 扫描窗口右侧的二维码



(6) 在手机微信 APP 上按照引导进行实名认证



(7) 依次点击“确定”按钮，然后关闭这个弹窗




2.4.3 获取一个 API-KEY


(1) 下拉一下这个网页的滚动条后可以看到一个超链接“安全认证-API-KEY”，点击它。



(2) 在自动弹出的新窗口中点击“创建 API-KEY”这个按钮。




(3) 鼠标单击服务对应的输入框，然后选择“千帆 ModelBuilder”。




(4) 将资源配置改为“所有资源”。


权限配置



(5) 点击“确定”按钮。



(6) 页面会自动弹出一个窗口显示生成的 API-KEY。




(7) 页面会自动弹出一个窗口显示生成的 API-KEY。


2.4.4 开通模型服务（根据 token 数量从百度账号中扣钱）

(1) 进入百度的模型购买界面

<https://console.bce.baidu.com/qianfan/ais/console/presetService>



(2) 在模型“ERNIE-5.0”对应的那一行点击“体验”




点击“体验”后，这个账号的 APIKEY 应该就能使用了

(3) 第一次调用不收费，但账号欠费如果不充值就会报错


3 调用大模型 API

3.1 创建测试脚本文件

(1) 在桌面创建一个项目文件夹，可以命名为“lab2”



(2)创建一个 test.py 文件



文件 test.py 的内容为:

```
config={
    "deepseek":{
        "api_key":"your-own-api-key",
        "base_url":"https://api.deepseek.com",
        "model":"deepseek-chat",
        "extra_body": {},
    },
    "tongyi":{
        "api_key":"your-own-api-key",
        "base_url":"https://dashscope.aliyuncs.com/compatible-mode/v1",
        "model":"deepseek-v3",
        "extra_body":{"enable_thinking": False},
    },
    "minimax":{
        "api_key":"your-own-api-key",
        "base_url":"https://api.minimaxi.com/v1",
        "model":"MiniMax-M2.7",
        "extra_body":{"reasoning_split": True},
    },
    "qianfan":{
        "api_key":"your-own-api-key",
```

```

        "base_url": "https://qianfan.baidubce.com/v2",
        "model": "ernie-5.0",
        "extra_body": {},
    },
    "localhost": {
        "model_path": "./DeepSeek-Model",
    }
}

param={
    "max_new_tokens": 1000, #256, #512      # 最大生成长度
    "temperature": 0.1, #0.7, #0.6          # 控制随机性 (0=确定性, 越高越随机)
    "stream" : False
}

import os
if os.path.exists(config["localhost"]["model_path"]):
    from transformers import AutoModelForCausalLM, AutoTokenizer # pip install transformers
torch accelerate

    config["localhost"]["model"] = AutoModelForCausalLM.from_pretrained(
        config["localhost"]["model_path"],
        torch_dtype="auto",                # 自动选择最佳数据类型 (如 fp16)
        device_map="cpu", # "cuda:0", #"auto",          # 自动分配到可用设备 (GPU 优先)
    )
    config["localhost"]["tokenizer"] =
AutoTokenizer.from_pretrained(config["localhost"]["model_path"])
modelId=""
for modelId in config:
    config[modelId]["messages"]=[{"role": "system", "content": "请用简洁、简短的语言回答用户的问题"}]
    # config[modelId]["messages"]=[{"role": "system", "content": "请专业且详细的回答用户的问题"}]
def chat_with_model(modelId, question):
    if not question:
        return "Please enter a question~"
    try:
        config[modelId]["messages"].append({"role": "user", "content": question})
        if modelId == "localhost":
            model=config[modelId]["model"]
            tokenizer=config[modelId]["tokenizer"]
            # 应用聊天模板生成模型输入
            text = tokenizer.apply_chat_template(
                config[modelId]["messages"], #history,
                tokenize=False,
                add_generation_prompt=True    # 为模型回复添加生成提示
            )
            # 分词并转移到模型所在设备

```

```

inputs = tokenizer(text, return_tensors="pt").to(model.device)
# 生成回复
outputs = model.generate(
    **inputs,
    max_new_tokens=256, #param["max_new_tokens"], #256, #512      # 最大生成长度
    temperature=param["temperature"], #0.1, #0.6                # 控制随机性 (0=确定性, 越高越随机)
    top_p=0.95,          # 核采样阈值
    do_sample=True,       # 启用采样 (否则为贪心解码)
    repetition_penalty=1.1, # 重复惩罚
    pad_token_id=tokenizer.eos_token_id #填充标记 (
)
# 解码生成部分 (仅保留新生成的 token)
response = tokenizer.decode(
    outputs[0][inputs.input_ids.shape[1]:],
    skip_special_tokens=True
)
else:
    import openai # pip install openai
    client = openai.OpenAI(
        api_key=config[modelId]["api_key"],
        base_url=config[modelId]["base_url"]
    )
    message = client.chat.completions.create(
        model=config[modelId]["model"],
        messages=config[modelId]["messages"],
        extra_body=config[modelId]["extra_body"],
        temperature=param["temperature"],
        max_tokens=param["max_new_tokens"], #1000
        stream=param["stream"] # 开启流式
    )
    if param["stream"]:
        response = ""
        print(" "+modelId+":", end="", flush=True)
        for chunk in message:
            if chunk.choices[0].delta.content is not None:
                content = chunk.choices[0].delta.content
                response += content
                print(content, end="", flush=True)
        print()
    else:
        response = message.choices[0].message.content
import re
response = re.sub(r'.*?</think>\s*', '', response, flags=re.DOTALL) # 删除 Chain of Thought
config[modelId]["messages"].append({"role": "assistant", "content": response})

```

```

        return response
    except Exception as e:
        return f"Failed to call model:{e}"
def initUI():# Gradio UI
    import gradio as gr # pip install gradio
    with gr.Blocks() as demo:
        gr.Markdown("## 🗨️ 多模型 LLM 聊天界面")
        model_selector = gr.Dropdown(choices=config.keys(), value=modelId, label="选择模型")
        with gr.Row():
            input_box = gr.Textbox(label="你的问题", placeholder="请输入你想问的问题", lines=1)
            send_button = gr.Button("发送")
        output_box = gr.Textbox(label="模型回答", interactive=False)
        send_button.click(chat_with_model, inputs=[model_selector, input_box], outputs=output_box)
    demo.launch(debug=True)
def initUI2():
    from flask import Flask, send_from_directory # pip install flask
    from flask_socketio import SocketIO, emit # pip install flask-socketio
    app = Flask(__name__)
    socketio = SocketIO(app)
    @app.route("/")
    def index():
        return send_from_directory(".", "test.html")
    @socketio.on("chatMessage")
    def handle_chat_message(data):
        model_id = data["modelId"]
        question = data["question"]
        try:
            response = chat_with_model(model_id, question)
        except Exception as e:
            response = str(e)
        emit("chatResponse", {"response": response})
    socketio.run(app, host="0.0.0.0", port=3000)
while True:
    prompt = input("our:")
    if len(prompt.split("switch-"))>1:
        str0 = prompt.split("switch-")[1]
        if str0 in config:
            modelId=str0
            print("已将 modelId 切换为:",modelId)
        elif str0=="gradio":
            print("[gradio]正在生成交互页面的链接...")
            initUI()
        elif str0=="html":
            print("正在生成交互页面的链接...")

```




```

    initUI2()
else:
    print("无法识别的切换目标:",str0)
    exit(0)
    continue
response = chat_with_model(modelId,prompt)
if not param["stream"]:
    print(" "+modelId+":", response)

```


(3)设置 API-KEY 字符串

- 将代码中对应位置的字符串替换为大家自己获取到的 API-KEY



3.2 通过 openai 调用 api

(1) 运行脚本：



(2) 通过百炼 API 测试 DeepSeek 大模型：



注意：API Key 需要和模型对应，如通义百炼和 MiniMax 模型的 API Key 不能混用。

(3) 测试 MiniMax 大模型:

```
switch-minimax
你是谁
(lab2) C:\Users\18763\Desktop\lab2>python test.py
our:switch-minimax
已将modelId切换为: minimax
our:你是谁?
minimax: 我是 MiniMax Air, 一个AI助手。有什么可以帮助你吗?
our:
```

(4) 测试 deepseek 大模型:

```
管理员: 命令提示符 - conda remove -n lab2 --all - activate lab2 - python test.py
(lab2) C:\Users\Administrator\Desktop\lab2>python test.py
our:switch-tongyi
已将modelId切换为: tongyi
our:你是谁
tongyi: 我是通义千问, 阿里巴巴集团旗下的超大规模语言模型。我能够帮助你回答问题、创作文字, 如写故事、公文、技术文档等, 还能表达观点, 玩游戏等。有什么我可以帮助你的?
our:switch-qianfan
已将modelId切换为: qianfan
our:你是谁
qianfan: 您好, 我是百度公司开发及训练的人工智能语言模型, 我的中文名是文心一言, 英文名是ERNIE Bot。我可以协助您完成范围广泛的任务并提供各种主题的信息, 比如回答问题, 提供定义、解释和建议。如果您有任何问题, 请随时
our:switch-deepseek
已将modelId切换为: deepseek
our:你是DeepSeek吗
deepseek: 不是哦, 我是 **DeepSeek Chat**, 由 **深度求索 (DeepSeek)** 开发的 AI 助手! © 我可以帮你解答各种问题、处理文档、分析数据, 还能陪你聊天。有什么我可以
our:
```

注意: deep seek 调用的时候如果处于高峰期可能会出现服务器无法响应的情况。

(5) 测试千帆大模型:

```
(lab2_3) G:\myFile\博二_下学期\助教HCI2026\lab2>python lab2_new2.py
our:switch-qianfan
已将modelId切换为: qianfan
our:你是谁
qianfan: 我是文心一言, 由百度训练的AI助手。
our:
```

注:


- 报错: "account_overdue."
错误分析: 账号欠费。

(6) 多轮对话测试:


```
our:switch-qianfan
已将modelId切换为: qianfan
our:你是谁
qianfan: 我是文心一言, 由百度训练的AI助手。
our:我叫orange
qianfan: 你好, Orange! 很高兴认识你。
our:我喜欢吃这种水果
qianfan: 橙子酸甜可口, 还富含维生素C, 是很健康的水果呢!
our:骗你的, 我其实不怎么爱吃它
qianfan: 哈哈, 被你逗到了! 那你平时喜欢吃什么水果?
our: _
```

4 本地部署大模型

4.1 填写大模型路径



4.2 重新启动程序




注：

- 该测试使用的仍然是本手册 3.1 中的脚本代码

4.3 测试模型推理功能

输入一些自然语言文本（如“你是谁”），观察模型推理出的回复是否合理：



5 通过“gradio”生成页面 UI

5.1 启动 gradio 后台

- (1) 在命令行中执行这个安装命令：

```
pip install --upgrade gradio
```

```
管理员: 命令提示符 - conda remove -n lab2 --all - activate lab2 - pip install --upgrade gradio
(lab2) C:\Users\Administrator\Desktop\lab2>pip install --upgrade gradio
Collecting gradio
  Downloading gradio-5.25.2-py3-none-any.whl.metadata (16 kB)
Collecting aiofiles<25.0,>=22.0 (from gradio)
  Using cached aiofiles-24.1.0-py3-none-any.whl.metadata (10 kB)
Requirement already satisfied: anyio<5.0,>=3.0 in d:\mysoftware\anaconda3\envs\lab2\lib\site-packages (from gradio) (4.9.0)
Collecting fastapi<1.0,>=0.115.2 (from gradio)
  Using cached fastapi-0.115.12-py3-none-any.whl.metadata (27 kB)
Collecting ffmpy (from gradio)
  Using cached ffmpy-0.5.0-py3-none-any.whl.metadata (3.0 kB)
Collecting gradio-client==1.8.0 (from gradio)
  Using cached gradio_client-1.8.0-py3-none-any.whl.metadata (7.1 kB)
Collecting groovy~=0.1 (from gradio)
  Using cached groovy-0.1.2-py3-none-any.whl.metadata (6.1 kB)
Requirement already satisfied: httpx<0.24.1 in d:\mysoftware\anaconda3\envs\lab2\lib\site-packages (from gradio) (0.28.1)
Collecting huggingface-hub<0.28.1 (from gradio)
  Using cached huggingface_hub-0.30.2-py3-none-any.whl.metadata (13 kB)
Collecting jinja2<4.0 (from gradio)
  Using cached jinja2-3.1.6-py3-none-any.whl.metadata (2.9 kB)
Collecting markupsafe<4.0,>=2.0 (from gradio)
  Using cached MarkupSafe-3.0.2-cp310-cp310-win_amd64.whl.metadata (4.1 kB)
Collecting numpy<3.0,>=1.0 (from gradio)
  Downloading numpy-2.2.5-cp310-cp310-win_amd64.whl.metadata (60 kB)
```

```
管理员: 命令提示符 - conda remove -n lab2 --all - activate lab2
Using cached pytz-2025.2-py2.py3-none-any.whl (509 kB)
Using cached rich-14.0.0-py3-none-any.whl (243 kB)
Using cached shellingham-1.5.4-py2.py3-none-any.whl (9.8 kB)
Using cached tzdata-2025.2-py2.py3-none-any.whl (347 kB)
Using cached websockets-15.0.1-cp310-cp310-win_amd64.whl (176 kB)
Using cached filelock-3.18.0-py3-none-any.whl (16 kB)
Using cached requests-2.32.3-py3-none-any.whl (64 kB)
Using cached charset-normalizer-3.4.1-cp310-cp310-win_amd64.whl (102 kB)
Using cached markdown-it-py-3.0.0-py3-none-any.whl (87 kB)
Using cached pygments-2.19.1-py3-none-any.whl (1.2 MB)
Using cached six-1.17.0-py2.py3-none-any.whl (11 kB)
Downloading urllib3-2.4.0-py3-none-any.whl (128 kB)
Using cached mdurl-0.1.2-py3-none-any.whl (10.0 kB)
Installing collected packages: pytz, pydub, websockets, urllib3, tzdata, tomlkit, six, shellingham, semantic-version, ru
ff, pyyaml, python-multipart, pygments, pillow, packaging, orjson, numpy, mdurl, markupsafe, groovy, fsspec, filelock, f
ffmpy, click, charset-normalizer, aiofiles, uvicorn, starlette, requests, python-dateutil, markdown-it-py, jinja2, safeht
tpx, rich, pandas, huggingface-hub, fastapi, typer, gradio-client, gradio
Successfully installed aiofiles-24.1.0 charset-normalizer-3.4.1 click-8.1.8 fastapi-0.115.12 ffmpy-0.5.0 filelock-3.18.0
fsspec-2025.3.2 gradio-5.25.2 gradio-client-1.8.0 groovy-0.1.2 huggingface-hub-0.30.2 jinja2-3.1.6 markdown-it-py-3.0.0
markupsafe-3.0.2 mdurl-0.1.2 numpy-2.2.5 orjson-3.10.16 packaging-25.0 pandas-2.2.3 pillow-11.2.1 pydub-0.25.1 pygments
-2.19.1 python-dateutil-2.9.0.post0 python-multipart-0.0.20 pytz-2025.2 pyyaml-6.0.2 requests-2.32.3 rich-14.0.0 ruff-0.
11.6 safehttpx-0.1.6 semantic-version-2.10.0 shellingham-1.5.4 six-1.17.0 starlette-0.46.2 tomlkit-0.13.2 typer-0.15.2 t
zdata-2025.2 urllib3-2.4.0 uvicorn-0.34.2 websockets-15.0.1

(lab2) C:\Users\Administrator\Desktop\lab2>
```

(2) 在命令行中执行这个脚本启动命令

```
python test.py
```

```
管理员: 命令提示符 - conda remove -n lab2 --all - activate lab2 - python test.py
markupsafe-3.0.2 mdurl-0.1.2 numpy-2.2.5 orjson-3.10.16 packaging-25.0 pandas-2.2.3 pillow-11.2.1 pydub-0.25.1 pygments
-2.19.1 python-dateutil-2.9.0.post0 python-multipart-0.0.20 pytz-2025.2 pyyaml-6.0.2 requests-2.32.3 rich-14.0.0 ruff-0.
11.6 safehttpx-0.1.6 semantic-version-2.10.0 shellingham-1.5.4 six-1.17.0 starlette-0.46.2 tomlkit-0.13.2 typer-0.15.2 t
zdata-2025.2 urllib3-2.4.0 uvicorn-0.34.2 websockets-15.0.1

(lab2) C:\Users\Administrator\Desktop\lab2>python test.py
our:
```

(3) 生成交互页面的链接

```
switch-gradio
```

```
管理员: 命令提示符 - conda remove -n lab2 --all - activate lab2 - python test.py
(lab2) C:\Users\Administrator\Desktop\lab2>python test.py
our:switch-gradio
正在生成的交互页面的链接...
* Running on local URL:  http://127.0.0.1:7860
To create a public link, set `share=True` in `launch()`.
```

5.2 测试前端 UI 界面

- (1) 在浏览器中打开生成的 URL 地址（http://127.0.0.1:7860）

多模型 LLM 聊天界面

选择模型

minimax

你的问题

请输入你想要问的问题

发送

模型回答

- (2) 在网页上进行测试

多模型 LLM 聊天界面

选择模型

minimax

你的问题

你是minimax吗

发送

模型回答

不是，我是基于Minimax模型开发的AI助手，由Minimax公司提供技术支持。

- (3) 切换到其它大模型

多模型 LLM 聊天界面

选择模型

tongyi

你的问题

你是DeepSeek吗?

发送

模型回答

是的! 我是 "DeepSeek Chat", 由 "深度求索 (DeepSeek)" 开发的智能助手。我可以帮你回答问题、提供建议、处理文档等。有什么我可以帮你的吗? 🤖

多模型 LLM 聊天界面

选择模型

deepseek

你的问题

你是DeepSeek Chat吗

发送

模型回答

是的! 我是 "DeepSeek Chat", 由 "深度求索 (DeepSeek)" 开发的AI助手。🤖 你可以问我任何问题，我会尽力帮你解答! 有什么我可以帮忙的吗?

6 通过“html”生成页面 UI

6.1 创建 html 文件

创建一个名称为 test.html 的文件，文件内容为：

```
<!DOCTYPE html>
<html lang="en">
<head>
  <meta charset="UTF-8">
  <meta name="viewport" content="width=device-width, initial-scale=1.0">
  <title>多模型 LLM 聊天界面</title>
  <!-- <script src="/socket.io/socket.io.js"></script> -->
  <script src="https://cdnjs.cloudflare.com/ajax/libs/socket.io/4.0.1/socket.io.js"></script>
  <style>
    body { font-family: Arial, sans-serif; }
    .container { max-width: 600px; margin: 0 auto; }
    .row { display: flex; justify-content: space-between; }
    textarea { width: 100%; }
  </style>
</head>
<body>
  <div class="container">
    <h2>🗨 多模型 LLM 聊天界面</h2>
    <div>
      <label for="modelSelector">选择模型:</label>
      <select id="modelSelector">
        <option value="deepseek">deepseek</option>
        <option value="tongyi">tongyi</option>
        <option value="qianfan">qianfan</option>
        <option value="minimax">minimax</option>
        <option value="localhost">localhost</option>
      </select>
    </div>
    <div class="row">
      <textarea id="inputBox" placeholder="请输入你想问的问题"></textarea>
      <button id="sendButton">发送</button>
    </div>
    <div>
      <label for="outputBox">模型回答:</label>
      <textarea id="outputBox" readonly></textarea>
    </div>
  </div>
```

```


<script>
  const socket = io();
  document.getElementById("sendButton").addEventListener("click", () => {
    const modelId = document.getElementById("modelSelector").value;
    const question = document.getElementById("inputBox").value;
    socket.emit("chatMessage", { modelId, question });
  });
  socket.on("chatResponse", (data) => {
    if (data.response) {
      document.getElementById("outputBox").value = data.response;
    } else {
      document.getElementById("outputBox").value = "Error: " + data.error;
    }
  });
</script>
</body>
</html>

```

6.2 建立 python 后台服务器

(1) 启动脚本:

```
python test.py
switch-html
```



```

C:\Users\Administrator\Desktop\HCI.exper\lab2>python test.py
our:switch-html
正在生成的交互页面的链接...
* Serving Flask app 'test'
* Debug mode: off
WARNING: This is a development server. Do not use it in a production deployment. Use a prod
uction WSGI server instead.
* Running on all addresses (0.0.0.0)
* Running on http://127.0.0.1:3000
* Running on http://100.81.109.75:3000
Press CTRL+C to quit
127.0.0.1 - - [22/Apr/2025 18:26:32] "GET /socket.io/?EIO=4&transport=polling&t=PPT2FgW HTTP
1.1" 200 -
127.0.0.1 - - [22/Apr/2025 18:26:32] "POST /socket.io/?EIO=4&transport=polling&t=PPT2F10&si
d=A8s21WZy15MHebobAAAA HTTP/1.1" 200 -
127.0.0.1 - - [22/Apr/2025 18:26:32] "GET /socket.io/?EIO=4&transport=polling&t=PPT2F1R&sid
=A8s21WZy15MHebobAAAA HTTP/1.1" 200 -
127.0.0.1 - - [22/Apr/2025 18:26:32] "GET /socket.io/?EIO=4&transport=polling&t=PPT2FqE&sid
=A8s21WZy15MHebobAAAA HTTP/1.1" 200 -

```

(2) 通过浏览器访问页面

🗨️ 多模型 LLM 聊天界面

选择模型: tongyi ▼

你是如何诞生的？

发送

模型回答:

我的诞生可以简单概括为以下几个关键阶段，由**深度求索（DeepSeek）**团队打造：

1. **技术基础**

- 基于前沿的**大语言模型（LLM）**技术，通过海量文本数据训练，学习语言规律、知识和推理能力。
- 结合深度学习框架（如Transformer结构）和高效算力优化，逐步提升模型性能。

2. **训练与迭代**

- **预训练**：在万亿级token的公开数据集上学习通用语言理解能力。
- **微调**：通过人类反馈强化学习（RLHF）和指令微调，让回答更符合用户需求。
- **持续优化**：根据用户反馈和实际应用场景不断升级模型。

3. **目标与使命**

- 初衷是打造一个**安全、有用、智能**的AI助手，帮助用户高效获取信息、解决问题。
- 支持多轮对话、长文本理解（128K上下文）、文件处理等实用功能。

4. **你的角色**

你的每一次提问和反馈都在帮助我成长！🌟

如果有具体的技术细节想了解，欢迎随时问我~ 😊